

Задача. Оценим время работы алгоритма ближайших соседей по количеству операций. Пусть X — обучающая выборка размера n , Y — тестовая выборка размера m . Размерность признакового пространства d .

Таким образом, $X \in \mathbb{R}^{n \times d}$, а $Y \in \mathbb{R}^{m \times d}$.

Квадрат евклидова расстояния между объектами x_i и y_j записывается как:

$$\rho(x_i, y_j) = \sum_{k=1}^d (x_i^k - y_j^k)^2.$$

- ▷ Определите количество операций, необходимое для подсчета всех попарных расстояний в наивном случае.
- ▷ Предложите способ, с помощью которого можно уменьшить количество операций. Оцените количество операций для предложенного метода.

Решение. Будем считать, что нам необходимо вычислить квадрат евклидова расстояния, иначе нам просто в конце подсчета каждой пары нужно взять корень и от этого мы никак не избавимся, то есть, грубо говоря, найдем количество операций для подсчета приведенной вами формулы для всех точек.

1. Нам необходимо вычесть вектор из вектора, далее возвести в квадрат и просуммировать d таких штук, то есть $3d$ операций итого. А так как нам нужно вычислить всевозможные попарные расстояния, то есть $n \times m$.

Получим $\approx 3d \times n \times m$ операций;

2. Перепишем в виде:

$$\rho(x_i, y_j) \equiv \|x_i - y_j\|^2 = \langle x_i - y_j, x_i - y_j \rangle = \|x_i\|^2 + \|y_j\|^2 - 2\langle x_i, y_j \rangle.$$

Замечание. Очевидно, под $\|\cdot\|$ всюду имеется ввиду $\|\cdot\|_{l_2}$.

Для пары (x_i, y_j) вычисление их скалярного произведения потребует $(2d-1)$ операций, так как это

$$\sum_{k=1}^d x_i^k y_j^k.$$

Теперь вычислим все квадраты норм, что займет $2d \times (n+m)$, и заметим, что их нужно считать лишь единожды по всем точкам для подсчета всевозможных пар точек;

Получим $\approx 2d \times nm + 2d \times (n + m)$ операций, что при $n, m \gg 1$ будет $2d \times nm$.

Итого сократили на целых dnm операций или же 33% на пустом месте.

Задача. Дано n объектов, распределённых равномерно внутри d -мерного единичного шара с центром в нуле.

- ▷ Найдите выражение для медианы расстояния от начала координат до ближайшего объекта.
- ▷ Проинтерпретируйте полученный результат в терминах применимости метода ближайшего соседа в различных ситуациях.

Считайте, что метрика в задаче евклидова.

Указание: попробуйте смоделировать событие и посчитать его вероятность в терминах функций распределения.

Решение.

1. Для удобства считаем центр шара в точке $\bar{0}$. Теперь вспомним одномерную функцию распределения для равномерного оного:

$$F_X(x) = x, \quad 0 \leq x < 1.$$

Обратим внимание, что это $\mathbb{P}(X \leq x)$, а нам надо $\mathbb{P}(X > x)$, то есть берем $1 - F_X(x)$.

Замечание. Случайная величина X_i — «бросок» i -ой точки в этот шар, так как все случайные величины в данной задаче (по крайней мере, я надеюсь) предполагаются *i.i.d.*, то я пишу X .

В нашем случае $x = r^d$, так как точки распределены равномерно внутри d -мерного шара (я предполагаю равномерно по объему).

Медиана одной случайной величины Y находится по определению из условия $F_Y(y) = 0.5$.

С учетом всего предыдущего:


$$(1 - r^d)^n = 0.5 \implies r = \sqrt[n]{1 - \frac{1}{2}}.$$

2. Я так полагаю, речь о применимости идет про классификацию точки в начале координат, то есть мы как бы рассматриваем окружающий её шар (если нет и мы хотим классифицировать какую-то другую точку в шаре, то не очень понятно как это анализировать, случаи могут быть абсолютно любые).

Попробуем проанализировать полученное выражение по модулю моего понимания условия. Рассмотрим крайние случаи, то есть

- (a) $d \gg n$. Тогда $r \rightarrow 1$, то есть в среднем ближайшая точка находится на поверхности шара, что плохо, ведь и самая дальняя точка находится где-то там (уж точно не дальше), а значит мы не можем «информативно» да и в принципе адекватно выбрать k соседей (ну только если $k \neq n$ или даже больше), все одно;
- (b) $n \gg d$. Тогда $r \rightarrow 0$ — тут все хорошо, ближайшая точка различима с не ближайшей, что означает какую-никакую сепарабельность, очевидно по модулю конкретных реализаций;
- (c) $n \approx d$. Тогда $r \rightarrow 1$ при достаточно больших n , что возвращает к первому пункту. Но стоит отметить, что если d мало, то есть порядка пары десятков или меньше, то метод даже можно применять.

Приложим картинку для последнего пункта (по OX n , он же d , по OY r):



Итого для применимости мы хотим, чтобы $n \geq d$ (притом $=$ допускается только если признаков порядка не более пары десятков), то есть количество точек больше, чем размерность пространства признаков, что довольно интуитивно.

Задача. Решается задача классификации с помощью алгоритма ближайших соседей (метрика евклидова). Для тестового объекта z ближайшим соседом с расстоянием ρ_x является x , вторым ближайшим соседом с расстоянием ρ_y является объект y . Остальные объекты обучающей выборки находятся от z на достаточно большом расстоянии.

Ко всем объектам добавляется новый признак: для z и y значение признака распределено равномерно на отрезке $[-1, 1]$, для всех остальных объектов значение признака равно нулю.

- ▷ Посчитайте вероятность того, что теперь ближайшим соседом для z будет не x , а y .
- ▷ Проинтерпретируйте полученный результат в терминах применимости метода ближайших соседей.

Указание: возможно в этой задаче пригодится знание криволинейных интегралов.

Решение.

1. Очевидно, так как

$$\rho_x < \rho_y \iff \rho_x^2 < \rho_y^2.$$


Мы хотим понять когда

$$\rho_y^{new} < \rho_x^{new}, \text{ что вновь эквивалентно } (\rho_y^{new})^2 < (\rho_x^{new})^2.$$

Зачем нужны квадраты? Это убирает корень. Также для удобства считаем точку z находящейся в точке $\bar{0}$ и пусть изначальное количество признаков d , то есть $y_{d+1} = Y$ — случайная величина, $z_{d+1} = Z$ тоже случайная величина. Тогда это можно переписать как

$$\begin{aligned} \sum_{k=1}^d y_k^2 + (Y - Z)^2 &< \sum_{k=1}^d x_k^2 + Z^2 \implies \\ \implies \rho_y^2 - \rho_x^2 &< 2YZ - Y^2 \iff 2YZ - Y^2 > \Delta > 0, \text{ где } \Delta = \rho_y^2 - \rho_x^2. \end{aligned}$$

Также отметим, что $2YZ - Y^2 \leq 1$ (видно если не раскрывать скобки). Итак, в координатах (Z, Y) это 2 области, ограниченные кривыми. Учтем еще, что $Z, Y \in [-1, 1]$, получается нам нужно, чтобы их область их пересечения была непуста, это будет значить, что такие пары (Z, Y) вообще есть. Для наглядности изобразил при $\Delta = 0.1$ с помощью Python (картинка справа). Остается записать, пусть вся область G . Тогда площадь можно записать как



$$S = \iint_G 1 dz dy$$

Притом

$$\begin{cases} z > \frac{\Delta + y^2}{2y} =: \varphi(y), & \text{при } y > 0; \\ z < \varphi(y), & \text{при } y < 0; \\ z^2 \leq 1, & y^2 \leq 1. \end{cases}$$

А так как $z \leq 1$, то

$$\frac{\Delta + y^2}{2y} < 1 \iff \frac{\Delta + y^2 - 2y}{2y} < 0 \implies y \in (1 - \sqrt{1 - \Delta}, 1].$$

Тогда


$$\begin{aligned} G_1 &= \int_{1-\sqrt{1-\Delta}}^1 \left(1 - \frac{\Delta + y^2}{2y}\right) dy = \int_{1-\sqrt{1-\Delta}}^1 \frac{-(y-1)^2 + (1-\Delta)}{2y} dy = \\ &= \frac{1}{2} \left(\sqrt{1-\Delta} + \frac{1-\Delta}{2} \right) + \frac{\Delta}{2} \ln(1 - \sqrt{1-\Delta}). \end{aligned}$$

Обратим внимание, что это и есть искомая вероятность, ведь с учетом симметрии — это $\mathbb{P} = G/S_{[-1,1]^2} = 2G_1/4 = G_1/2$.

Итого

$$\mathbb{P} = \begin{cases} \frac{1}{4} \left(\sqrt{1-\Delta} + \frac{1-\Delta}{2} \right) + \frac{\Delta}{4} \ln(1 - \sqrt{1-\Delta}), & \Delta < 1 \\ 0, & \Delta \geq 1. \end{cases}$$

Для наглядности построим график $\mathbb{P}(\Delta)$:



2. Что можно сказать по полученным результатам:


Добавление даже одного дополнительного признака даёт ненулевую вероятность изменения ближайшего соседа, при этом она определяется лишь разницей квадратов «изначальных» расстояний Δ . Причем $\mathbb{P} \rightarrow 0$, $\Delta \rightarrow 1$, а если $\Delta > 1$, то $\mathbb{P} = 0$.

Это показывает чувствительность kNN'а к «масштабам», чем ближе изначально находятся точки, тем более вероятно получить такой прикол (но все же $< 1/2$), когда даже один новый признак может значительно изменить найденных соседей и, следовательно, предсказание (очевидно с учетом того, что они все равнозначные итд), однако если расстояния между точками заведомо достаточно большие, то вообще ничего не поменяется.

Задача. Докажите, что ROC-AUC случайного классификатора равен 0.5.

Решение.

Сначала интуитивно: вспомним как выглядит распределение равномерной случайной величины (картинка справа с вики, в нашем случае $a = 0$, $b = 1$) и то, что $F_\xi(x) = \mathbb{P}(\xi < x)$, а каждая точка ROC относится к определенному числовому порогу бинаризации/разделения (что по сути и есть x). Вот мы и получили площадь 0.5, но теперь более формально:



Из доп материалов курса мы знаем, что

$$ROC - AUC = \mathbb{P}(a_i < a_j | y_i < y_j) + \frac{\mathbb{P}(a_i = a_j | y_i < y_j)}{2}.$$

Так как классификатор случайный, то

$$\mathbb{P}(a_i < a_j | y_i < y_j) = \mathbb{P}(a_i > a_j | y_i < y_j) = a \implies \mathbb{P}(a_i = a_j | y_i < y_j) = 1 - 2a.$$

Подставляем в формулу выше и получаем

$$ROC - AUC = a + \frac{1 - 2a}{2} = 1/2, \text{ Ч.т.д.}$$

Задача. Пусть $a = a(x)$ ответ алгоритма. На сколько может уменьшиться ROC-AUC при использовании функции $\min(a, 0.5)$ над оценками алгоритма?

Решение. Как и в первой задаче вспомним, что


$$ROC - AUC_1 = \mathbb{P}(a_i < a_j | y_i < y_j) + \frac{\mathbb{P}(a_i = a_j | y_i < y_j)}{2}.$$

После использования функции получим следующее:

$$ROC - AUC_2 = \mathbb{P}(\min(a_i, 0.5) < \min(a_j, 0.5) | y_i < y_j) + \frac{\mathbb{P}(\min(a_i, 0.5) = \min(a_j, 0.5) | y_i < y_j)}{2}.$$

Теперь подумаем что могло произойти:

- Если $a \equiv 0.5$, то ROC-AUC не поменялся (это как была прямая $(0, 0) \rightarrow (1, 1)$, так и осталась;
- Если $a_i < a_j$, то очевидно $\min(a_i, 0.5) \leq \min(a_j, 0.5)$, знак больше никак получится не может, а значит для каждой такой пары точек они «перешли в правую часть суммы», то есть их вклад в площадь в дискретном случае с δ уменьшился до $\delta/2$, где δ — площадь «единичного прямоугольника». А значит, мы как бы «спроектируем» кусок кривой «над» прямой $y = x$ на нее, то есть в худшем случае получим падение площади с 1 (что соответствует идеальному классификатору) до $1/2$. Картинку примерно происходящего прилагаю:



Обратим внимание, что $S'_2 = S_2$, так как с частью кривой под прямой $y = x$ ничего не происходит, так как это соответствует точке < 0.5 (если она уже возникает), а значит функция $\min$ на неё не повлияет;

Ответ: на $\Delta \in [0, 0.5]$.

Задача. Пусть на ответах алгоритма m (принимающих значения от 0 до 1) задано распределение объектов класса 1 (доля объектов класса 1 в зависимости от ответа алгоритма) следующим образом:

$$\mathbb{P}(m \in [a, b] \mid y = 1) = \int_a^b p(z) dz.$$

Распределение объектов класса 0 задаётся так:

$$\mathbb{P}(m \in [a, b] \mid y = 0) = \int_a^b (2 - p(z)) dz,$$

где $p(z) = -1.5z^2 + 3z$.

Найдите вероятностные оценки на величины TPR , FPR и $ROC-AUC$.

Решение. Фиксируем α . Тогда с учетом того, что TPR при фиксированном значении параметра — доля верно классифицированных 1, а то есть вероятность, получаем ($a = \alpha$, $b = 1$):

$$TPR(\alpha) = \mathbb{P}(m \geq \alpha \mid y = 1) = \int_{\alpha}^1 (-1.5z^2 + 3z) dz = 1 - (-0.5\alpha^3 + 1.5\alpha^2) = \frac{\alpha^3}{2} - \frac{3\alpha^2}{2} + 1.$$


Аналогично для FPR :

$$FPR(\alpha) = \int_{\alpha}^1 (2 + 1.5z^2 - 3z) dz = 1 - (2\alpha + 0.5\alpha^3 - 1.5\alpha^2) = -\frac{\alpha^3}{2} + \frac{3\alpha^2}{2} - 2\alpha + 1.$$

А так как получено параметрическое уравнение ROC-кривой, то далее, как в доп материалах,

$$ROC - AUC = \int_1^0 TPR(\alpha) FPR'(\alpha) d\alpha = \int_1^0 \left(\frac{\alpha^3}{2} - \frac{3\alpha^2}{2} + 1 \right) \left(-\frac{3\alpha^2}{2} + 3\alpha - 2 \right) d\alpha = \frac{3}{4}.$$

Построим саму кривую с помощью Desmos:



Вроде всё верно...